

Fundamentos de Neurocomputación

De la lógica simbólica al aprendizaje profundo.

Paulo Daniel Vázquez Mora
Universidad Iberoamericana Puebla

Dos enfoques de la inteligencia

Simbólico (Top-Down)

Basado en reglas explícitas, lógica formal y símbolos definidos. El programador modela el conocimiento directamente. Se asume que la inteligencia es un razonamiento estructurado. Efectivo, pero rígido ante lo desconocido.

Conexionista (Bottom-Up)

Inspiración biológica. El modelo pasa directamente del nivel de conocimiento al nivel físico. El aprendizaje ocurre a partir de los datos mediante el ajuste de parámetros (pesos). La inteligencia emerge de interacciones simples. Ideal para entornos cambiantes.

Dos enfoques de la inteligencia

Simbólico (Top-Down)




Conexionista (Bottom-Up)




Modelo de McCulloch-Pitts (1943)

El primer paso formal hacia la neurocomputación. Inspirados en los descubrimientos de Cajal, abstraieron la neurona como un interruptor binario (on/off) capaz de implementar conectivos lógicos (AND, OR, NOT).




La anatomía de la unidad.




El Disparador: Funciones de Activación


La no-linealidad matemática que permite resolver problemas complejos. Sin ellas, una red multicapa sería equivalente a una simple regresión lineal.



Sigmoide: Probabilidad (0 a 1). Histórica, pero sufre del problema de gradientes desvanecientes en los extremos.



Tanh: Simetría (-1 a 1). Centrada en cero, permite un mejor flujo de gradientes que la sigmoide.



ReLU: Eficiencia Moderna. El estándar actual. Computacionalmente ligera y mitiga el desvanecimiento del gradiente.

El Disparador: Funciones de Activación

La no-linealidad matemática que permite resolver problemas complejos. Sin ellas, una red multicapa sería equivalente a una simple regresión lineal.



Sigmoide: Probabilidad (0 a 1).
Histórica, pero sufre del problema de gradientes desvanecientes en los extremos.




Tanh: Simetría (-1 a 1).
Centrada en cero, permite un mejor flujo de gradientes que la sigmoide.




ReLU: Eficiencia Moderna.
El estándar actual.
Computacionalmente ligera y mitiga el desvanecimiento del gradiente.

El Perceptrón y la barrera XOR

Un perceptrón simple (una sola capa) solo puede resolver problemas linealmente separables. Minsky y Papert (1969) demostraron esta limitación matemática.



Separable Linealmente




El Límite Matemático

Esta demostración provocó el primer Invierno de la IA.

La Solución: Redes Multicapa (MLP)


Añadir capas ocultas permite a la red crear representaciones intermedias y **no-lineales**, rompiendo la barrera espacial del XOR. (Teorema de Aproximación Universal).




EL GRANJERO Y LA CERCA RECTA

CONTEXTO


TEMPORADA 1 (Problemas AND / OR)



TEMPORADA 2 (El Dilema del XOR)




LA SOLUCIÓN (Perceptrón Multicapa) - OPCIÓN A




OPCIÓN B

Crea una terraza en un segundo piso (3D), elevando las esquinas de los manzanos. Una cerca y plana inclinada pasa por debajo del piso elevado y separa los cultivos fácilmente.



1. Pase Forward y Función de Pérdida



EL ARQUERO VENDADO - El Silbato del Maestro

CONTEXTO: El Arquero y el Silbato

EL ARQUERO VENDADO
(El Modelo o Red Neuronal)



MEDICIÓN DE LA PÉRDIDA Y COMPORTAMIENTO DE APRENDIZAJE

Silbido Ensordecedor (Pérdida L2)

Si el fallo es grande, el silbido es ENORME. Elevado al cuadrado, el error L2 avisa de un fallo garrafal.



MEDICIÓN DE LA PÉRDIDA Y COMPORTAMIENTO DE APRENDIZAJE

Silbido Ensordecedor (Pérdida L2)

Si el fallo es grande, el silbido es ENORME. Elevado al cuadrado, de un fallo garrafal.



Silbido Suave

Si el fallo es pequeño, el silbido es tenue.




EL MODELO HA APRENDIDO CON ÉXITO

Tras cientos de flechas, el arquero ha ajustado su postura ($\hat{y} \approx y$). El silbato se silencia (Pérdida ≈ 0).




2. Descenso de Gradiente y Backpropagation




Backpropagation: El cálculo de la culpa.
Usar la regla de la cadena (cálculo diferencial) hacia atrás para descubrir cómo contribuyó cada peso individual al error total.

Descenso de Gradiente: El motor de optimización.
Actualizar iterativamente los pesos (w) para moverse hacia el error mínimo en el paisaje de pérdida.



LA LÍNEA DE ENSAMBLAJE: RETROPROPAGACIÓN (BACKPROPAGATION)


PASO 1: LA PREDICCIÓN (FEEDFORWARD)



PASO 2: MEDICIÓN DEL DEFECTO Y LA PÉRDIDA



PASO 3: RETROPROPAGACIÓN DEL ERROR (BACKPROPAGATION)




PASO 4: APRENDIZAJE / AJUSTE DE POSTURAS (DESCENSO DE GRADIENTE)

EL MODELO APRENDE CON ÉXITO: AJUSTE DE PESOS (w)



Síntesis: La Anatomía del Aprendizaje




EL MONTAÑISTA EN LA NIEBLA: DESCENSO DE GRADIENTE

RED NEURONAL
PESOS w → ENTRADA → SALIDA ($\hat{y}$)
 $w_{new} = w_{old} - \alpha \cdot \nabla L$

El proceso para encontrar el punto de error mínimo (el valle)
en un espacio de parámetros (la montaña)

CONSTITUCIÓN DE LA MONTAÑA (El Espacio de Error)



INCLINACIÓN DEL PIE (Medición del Gradiente)



EL PASO HACIA ABAJO (Determinación de la Tasa de Aprendizaje α)

Escenario A: Tasa de Aprendizaje (α) Óptima



Escenario B: Tasa de Aprendizaje (α) Muy Grande



REGULACIÓN DE LA TASA DE APRENDIZAJE (α): Controla la longitud del paso

REPETICIÓN HASTA EL FONDO (El Descenso Completo)



Los límites de la red Multicapa

Explosión de Parámetros

Conectar todo con todo (Fully Connected) es ineficiente. En imágenes grandes, genera millones de pesos, haciendo la red propensa al sobreajuste y costosa de computar.

Ceguera Espacial

El MLP aplana los datos en vectores de 1D. No entiende la topología en cuadrícula; pierde la noción de que dos píxeles están uno al lado del otro.

Amnesia Secuencial

Es una arquitectura estática. No tiene memoria interna ni estados ocultos, por lo que no puede procesar el tiempo ni secuencias estructuradas (como el lenguaje o el video).

Referencias Bibliográficas

Google. (2026). Gemini Notebook [Asistente de IA generativa].
<https://notebook.google>

Russell, S. J., & Norvig, P. (2020). Inteligencia artificial: Un enfoque moderno (4a ed.). Pearson Education.

Shah, D. (2024, 24 de julio). What is a Reasoning Engine? Coralogix.
<https://coralogix.com/ai-blog/what-is-a-reasoning-engine/>

Vázquez Mora, P. D. (2026). Syllabus de la Asignatura: Agentes Inteligentes (LIIS1213). Universidad Iberoamericana Puebla.