

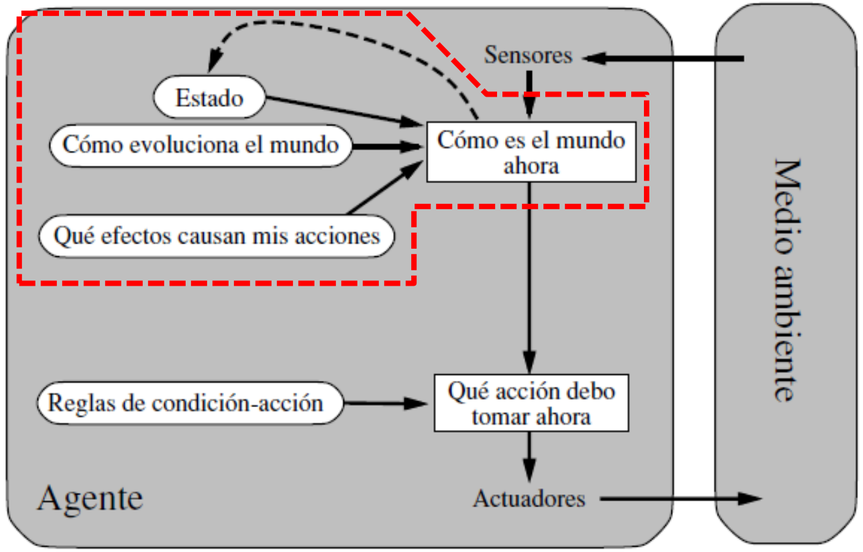
IBERO
PUEBLA

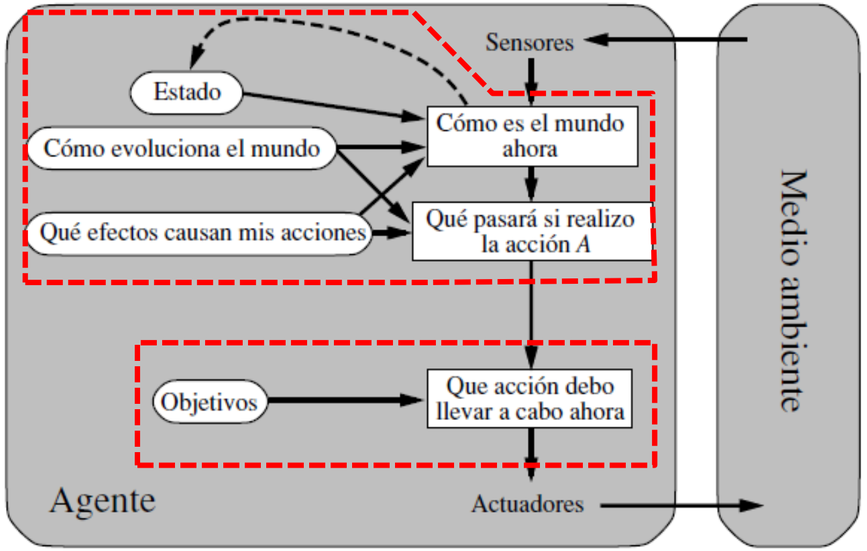
Estado interno de los agentes inteligentes

Impartido por: Paulo Daniel Vázquez Mora

Introducción

Dentro del ámbito de los agentes inteligentes (AI), tanto el **modelo del mundo** como el **modelo de la tarea** son elementos fundamentales para aquellos agentes que necesitan tomar decisiones complejas, planificar y operar de forma autónoma en entornos dinámicos y con observación parcial.





El modelo del mundo (world model)

El **modelo del mundo** es la representación interna que un agente inteligente tiene de su entorno. Esencialmente es el conocimiento que el agente posee sobre cómo funciona el mundo que lo rodea.

El **modelo del mundo** es un componente de memoria y razonamiento que le permite al agente mantener un registro de los aspectos del entorno que no son directamente observables en un momento dado, así como predecir los resultados de sus acciones.

Componentes del modelo del mundo

- **Estado interno:** Un registro de los aspectos del entorno no observables que son relevantes para el agente.
- **Modelo de transición (o dinámica):** El conocimiento sobre cómo evoluciona el mundo independientemente de las acciones del agente y, crucialmente, cómo las acciones del agente afectan el estado del mundo. Ejemplo: Si la acción es "encender la luz", el modelo de transición predice que el estado del mundo cambiará de "luz apagada" a "luz encendida".
- **Modelo de percepción:** El conocimiento sobre la relación entre el estado actual del mundo y las percepciones (lo que el agente detecta a través de sus sensores). Permite al agente estimar su estado real a partir de percepciones limitadas.

Función del modelo del mundo

- **Manejar la observabilidad parcial:** Si el agente no puede (percibir) ver todo el entorno en un instante, el modelo del mundo le permite inferir o recordar las partes ocultas.
- **Simulación mental (predicción):** El agente puede imaginar o simular internamente el resultado futuro de las acciones posibles antes de ejecutarlas, lo cual es fundamental para la planificación y la toma de decisiones racionales.

El modelo de la tarea (task/goal model)

El **modelo de la tarea** es el conjunto de información que define el objetivo que el agente debe alcanzar y, a menudo, los procedimientos o pasos necesarios para lograrlo. Es la brújula que guía el comportamiento del agente.

El modelo de la tarea describe lo que se espera que el agente haga. En agentes complejos, esto puede implicar una jerarquía de metas y submetas, o una función de utilidad que cuantifica la deseabilidad de diferentes estados del mundo.

Componentes del modelo de la tarea

- **Metas y submetas:** Los estados o situaciones que el agente desea lograr. Las tareas complejas se descomponen en tareas más pequeñas y manejables (**modelado jerárquico de tareas - hierarchical task network o htn**).
- **Función de utilidad (o recompensa):** En agentes basados en utilidad (como en el aprendizaje por refuerzo), es una métrica que define la preferencia del agente por un estado del mundo sobre otro, o la recompensa recibida al realizar una acción. Es la medida de "éxito" del agente.
- **Restricciones y precondiciones:** El conocimiento de las condiciones que deben cumplirse para que una acción se pueda ejecutar (precondiciones) y las limitaciones del entorno o del agente.

Función del modelo de la tarea

- **Definir la racionalidad:** Una acción es racional si ayuda al agente a alcanzar sus metas o a maximizar su utilidad esperada. El modelo de la tarea proporciona el criterio para evaluar si una acción es "buena".
- **Planificación:** El agente utiliza este modelo para generar una secuencia de acciones que, según su **modelo del mundo**, lo llevarán desde el estado inicial hasta el estado deseado (la meta).

Interacción entre modelos del mundo y de la tarea

El modelo del mundo y el modelo de la tarea trabajan juntos para permitir una toma de decisiones inteligente y proactiva.

Aspecto	Modelo del Mundo (World Model)	Modelo de la Tarea (Task Model)
Pregunta Clave	¿Qué sucederá si tomo esta acción? (Predicción)	¿Qué quiero lograr? (Objetivo)
Naturaleza	Descriptiva (Conocimiento del entorno)	Prescriptiva (Definición de metas/éxito)
Base para la Decisión	Las posibles consecuencias de las acciones.	La evaluación de qué tan deseables son esas consecuencias (utilidad).

Relación funcional

- El agente percibe el entorno y **actualiza** su Modelo del Mundo.
- El agente consulta su **modelo de la tarea** para saber qué objetivo quiere alcanzar.
- El agente utiliza su **modelo del mundo** para planificar la secuencia de acciones que, según su conocimiento, lo llevarán a lograr el objetivo definido en el **modelo de la tarea**.
- El agente ejecuta la acción óptima determinada por la planificación.

Esta sinergia es lo que distingue a los agentes inteligentes de los sistemas reactivos simples (que solo tienen reglas de condición-acción), otorgándoles capacidad de raciocinio, planificación y adaptación a largo plazo.

Referencias

- Russell, S. J. & Norvig, P. (2004). Inteligencia artificial, un enfoque moderno. Prentice-Hall, Capítulo II. Recuperado de https://luismejias21.wordpress.com/wp-content/uploads/2017/09/inteligencia-artificial-un-enfoque-moderno-stuart-j-russell.pdf
- Gutowska, A., Stryker, C. (2025). The 2025 Guide to AI Agents. Recuperado de https://www.ibm.com/think/ai-agents

¡gracias!

IBERO
PUEBLA